

Intelligent Charging Station

Bastian Berle
Fabian Heidger
Ron Holzapfel



Energie- & Transportsektor
verantworten > **50%** weltweiter **CO2-Emissionen**

Erreichung des **2 Grad Ziels** nur mit
disruptiven Lösungen in beiden
Sektoren



> **680 Tsd. E-Autos** in **DE** (5x mehr
als 2020)

Verändertes **Anforderungsprofil**

Größere **Batteriekapazitäten**



Was, wenn **49 Mio. zugelassene E-Autos** in DE?

Grüner Transport, aber **schmutzige Energieversorgung?**

Weiterhin **Gewährleistung** von
Energie auch in **anderen Bereichen**

Lademanagement & Netzinfrastruktur

Der Wissenschaftliche Beirat des **BMVI** identifizierte folgende Herausforderungen:



Aufladen während der
Stoßzeiten



Ausbau der
Netzinfrastruktur



Freie Mobilität
gewährleisten



Erhöhte Nachfrage
kann mit erneuerbaren
Energiequellen schwer
gedeckt werden



Bedarf und
Organisationsmodelle
für **Ladeinfrastruktur**
prüfen

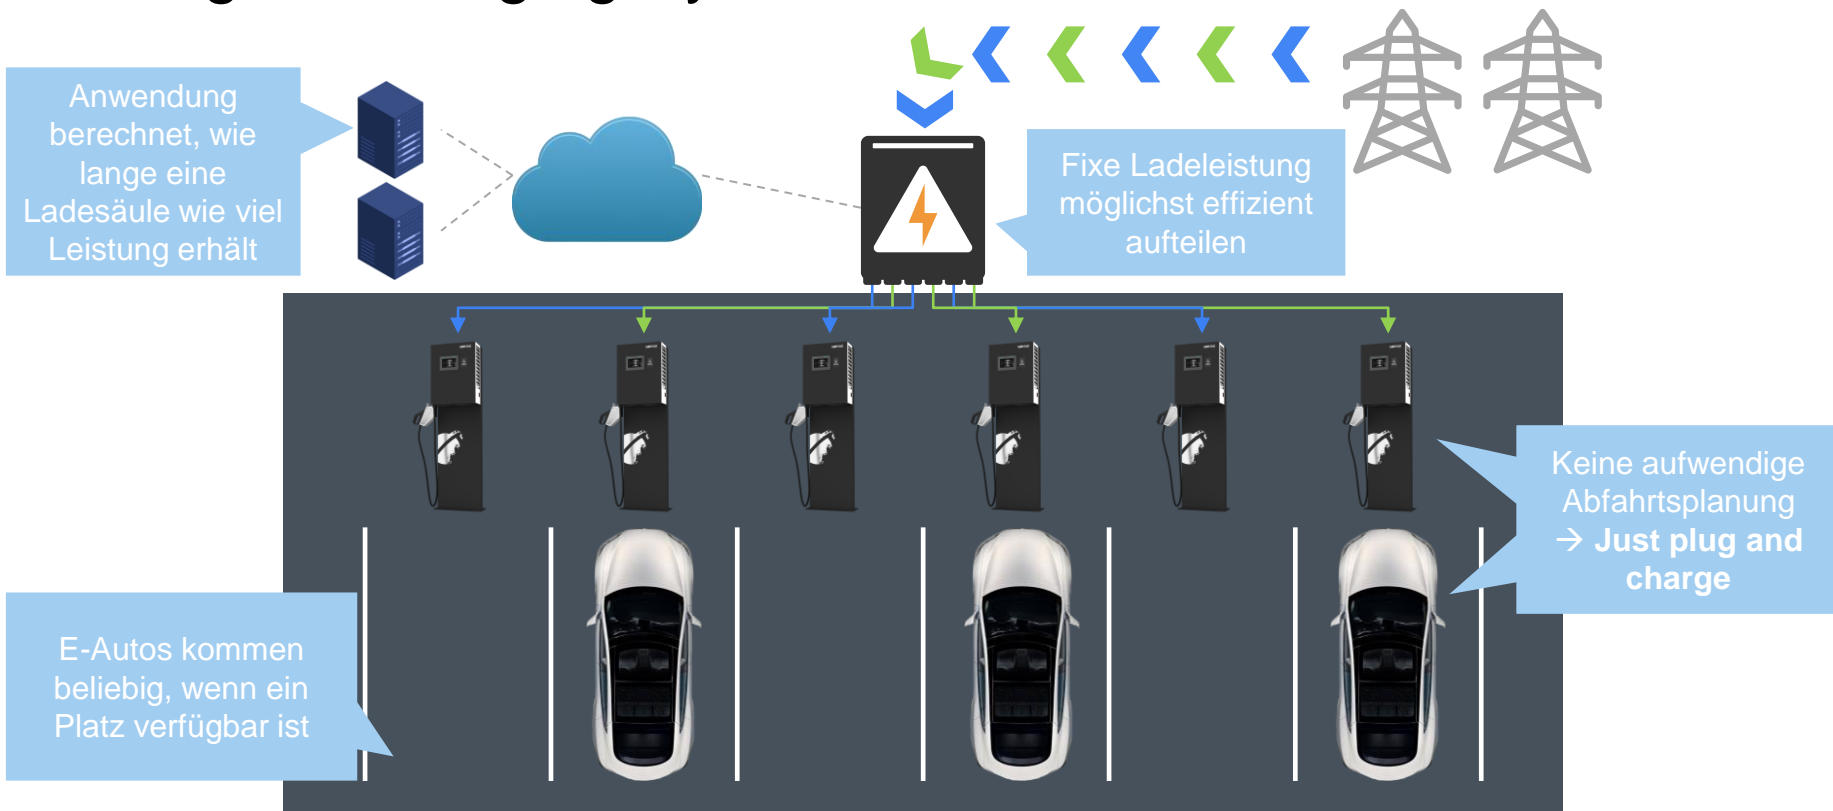


Netzstabilität:
Energieversorgung
auch in anderen
Bereichen
gewährleisten



Netzlimitationen
berücksichtigen

Intelligent Charging System



Reinforcement Learning

Abbildung als Matrix



Wie sieht der Zustand des Environments aus?



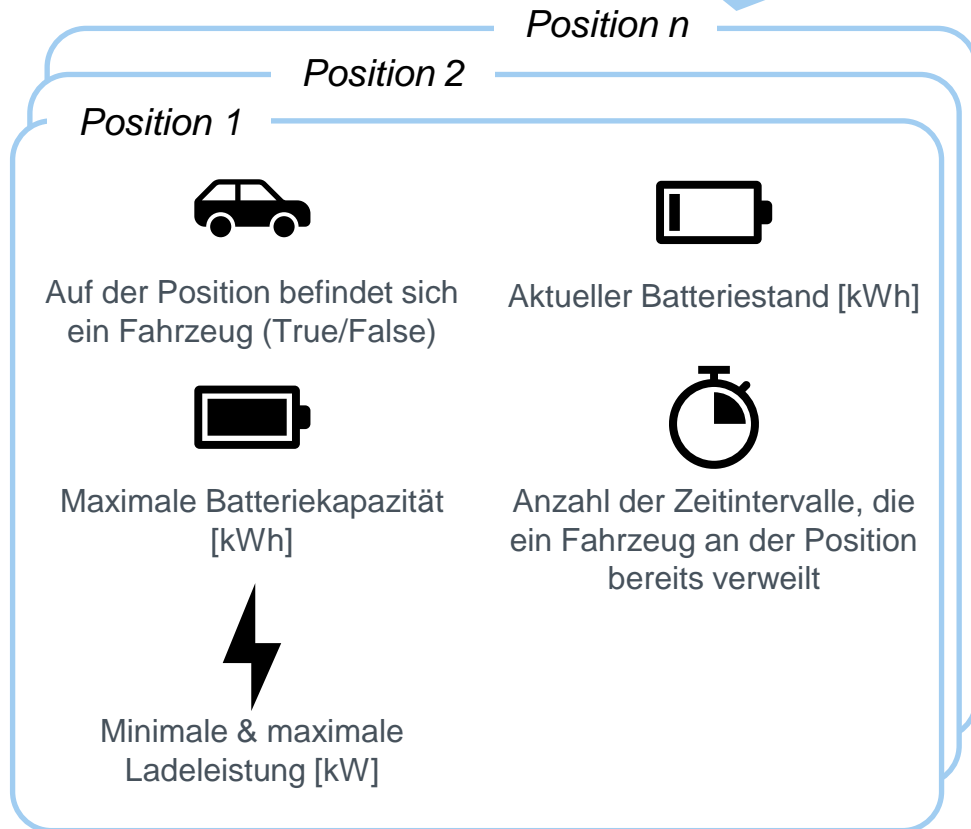
Was ist der Reward?



Welches Modell kann verwendet werden?



Wie wird das Modell trainiert?



Reinforcement Learning



Wie sieht der Zustand des Environments aus?



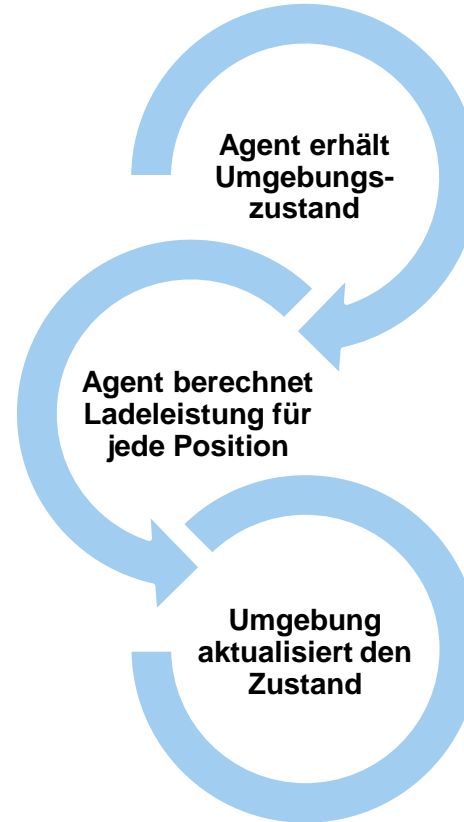
Was ist der Reward?



Welches Modell kann verwendet werden?



Wie wird das Modell trainiert?



Reward entspricht der Differenz aller Batteriekapazitäten zwischen den Zeitintervallen



Reinforcement Learning



Wie sieht der Zustand des Environments aus?



Was ist der Reward?




Welches Modell kann verwendet werden?



Wie wird das Modell trainiert?

Klassische DQNs sind nicht in der Lage kontinuierliche Vorhersagen zu treffen ...

Deep Deterministic Policy Gradient



Actor

entscheidet, welche Aktion durchgeführt werden soll

Critic

bewertet die Aktion des Actors und gibt an, wie diese Aktion angepasst werden sollte

Reinforcement Learning



Wie sieht der Zustand des Environments aus?



Was ist der Reward?



Welches Modell kann verwendet werden?




Wie wird das Modell trainiert?

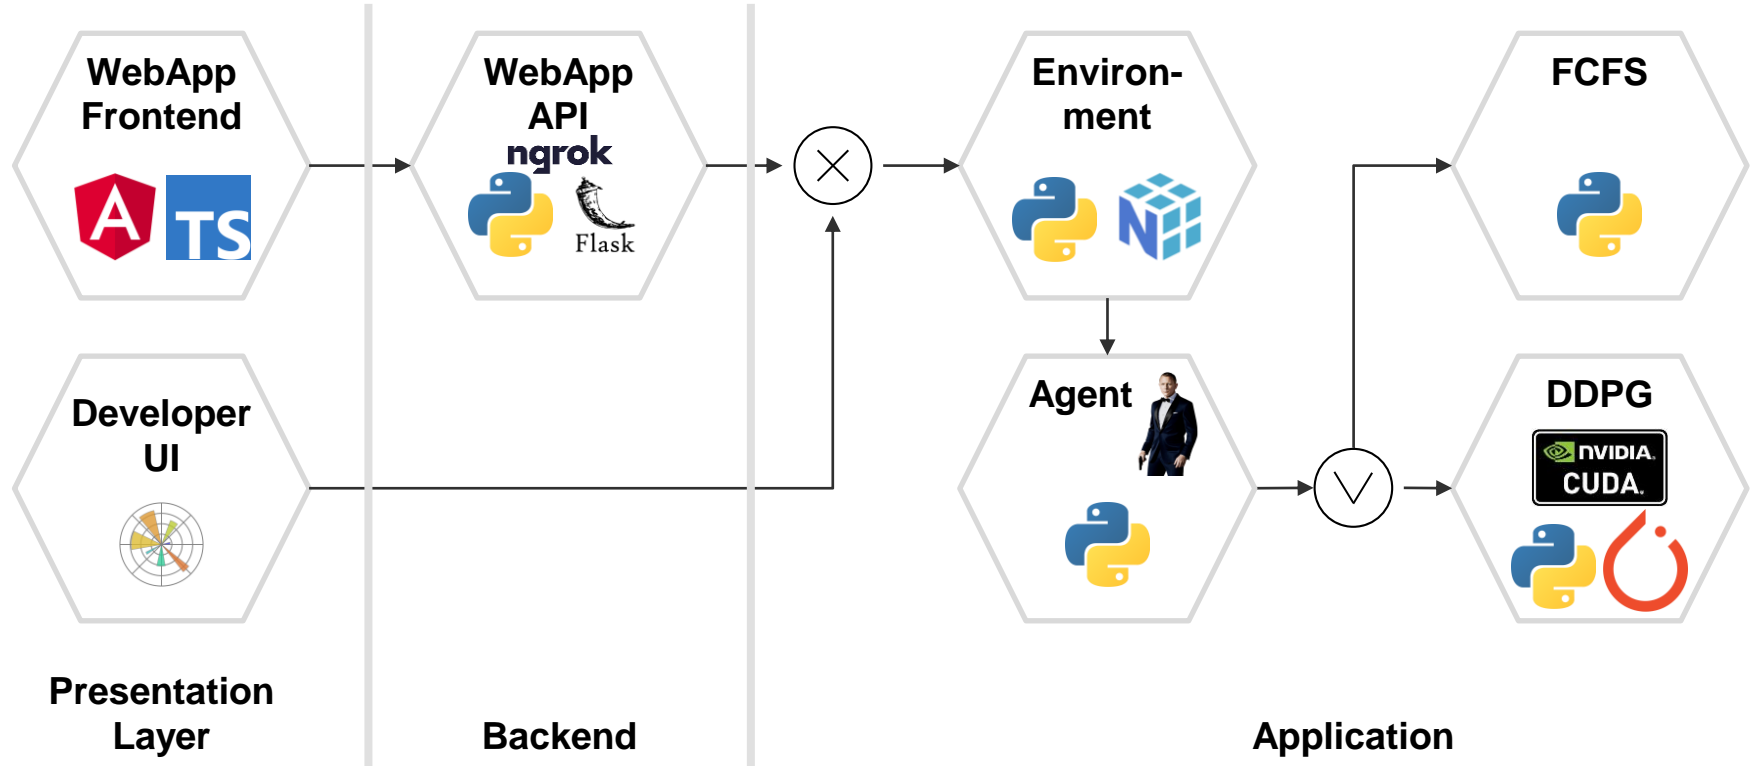
Mithilfe des **Epsilon-Greedy-Verfahren** wird im Training zunächst ein Grundschatz von Erfahrung gesammelt, bis nach und nach der Agent immer häufiger Entscheidungen trifft...

Entscheidungen werden temporär im **Replay Buffer** (Queue) gespeichert



Stabileres Lernen durch **Target-** und **Train-Modelle**



Produktarchitektur & Technologie-Stack



Ergebnisse



Fazit

Zielerreichung



Funktionierendes AI-System



Nutzbare Frontend



Potentiellen Investoren kann ein „funktionsfähiges“ PoC vorgestellt werden

Kritische Würdigung



FCFS ist nicht der intelligenteste nicht-AI Algorithmus

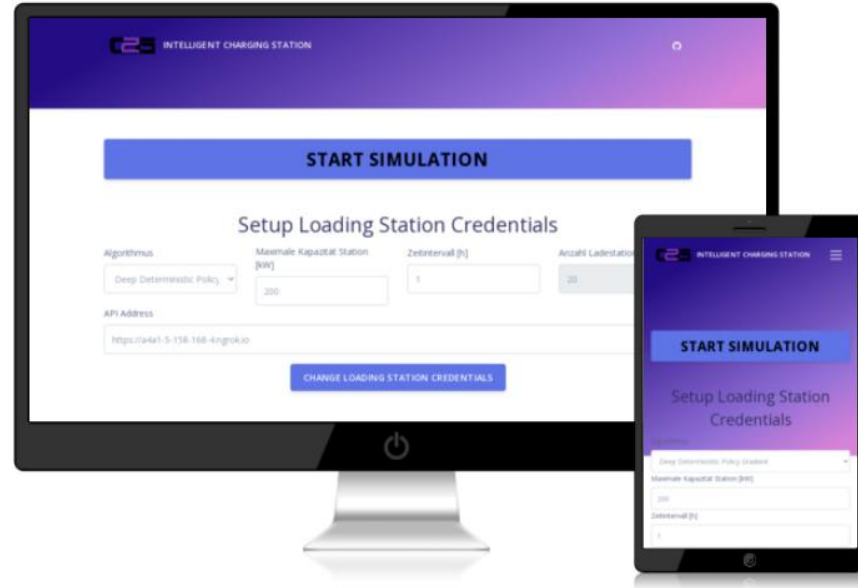


Gewisser Bias durch geringe Variantenvielfalt während des Trainings



Batterieforschung noch im frühen Stadium
→ disruptive Techniken können unsere Plattform unbenutzbar machen

Demo



<https://coin2gether.de>

Titel	Ansatz	Unterschied zu unserem Use Case
Intelligent Electric Vehicle Charging Recommendation Based on Multi-Agent Reinforcement Learning (Link)	<ul style="list-style-type: none"> • jede Ladestation entspricht einem eigenen RL-Agenten • Berücksichtigung von weiteren Einflüssen wie Gebührenwettbewerb oder verzögerte Zugriffsstrategien • Ergebnisse aus einem durchgeführten Experiment sind vielversprechend 	<ul style="list-style-type: none"> • In dem Paper geht es primär um die Generierung von Empfehlungen hinsichtlich einer passenden Ladestation, das auf einem Pool von geografisch verteilten Ladestationen zurückgreift
Optimal Placement of Public Electric Vehicle Charging Stations Using Deep Reinforcement Learning (Link)	<ul style="list-style-type: none"> • Anhand des prognostizierten Ladebedarfs und der aktuellen Ladestationen einen optimalen Standort für neue Ladestationen zu finden • Faktoren: Verkehrsdichte im Umkreis, die Registrierung von E-Fahrzeugen & Nähe zu bestimmten Arten von öffentlichen Gebäuden 	<ul style="list-style-type: none"> • Es geht primär um die Findung von neuen Ladestationen
Smart charging of electric vehicles using reinforcement learning (Link)	<ul style="list-style-type: none"> • Problemstellung die behandelt werden soll ist die Sicherstellung von Netzstabilität unter Berücksichtigung des Ladeverhalten und der allgemeinen Kostenminimierung, welche sich durch Angebot und Nachfrage zusammensetzt • Ein RL-Agent soll das Verbrauchsverhalten von Haushalten erlernen, der das Ziel der individuellen Wohlfahrtsmaximierung berücksichtigt • Ergebnisse des Experiments sind vielversprechend und basieren auf statistischen Kundenmodelle • Der Agent konnte die Energiepreise reduzieren und zugleich die allgemeine Auslastung inkl. Spitzenlasten im Netz reduzieren 	<ul style="list-style-type: none"> • In unserem Anwendungsfall geht es nicht ausschließlich um die Senkung der Energiepreise, sondern um das intelligente Verteilen von Ressourcen

Titel	Ansatz	Unterschied zu unserem Use Case
<p>Deep reinforcement learning for energy management in a microgrid with flexible demand (Link)</p>	<ul style="list-style-type: none"> • Optimierte Ressourcenverteilung innerhalb eines neuartigen Mikronetzmodell, das aus Windturbinen, Energiespeichersystemen, einer Reihe von thermostatisch gesteuerten Konsumenten, einer Reihe von preisabhängigen Konsumenten und einem Anschluss an das Hauptnetz besteht • Innerhalb eines Experiments wurden mehrere DL-Ansätze getestet • Die besten Ergebnisse erzielte ein "asynchronous advantage actor-critic"-Modell, das zusätzlich auf eine "experience replay" zurückgreift 	<ul style="list-style-type: none"> • Im Fokus liegt erneut die Preiskomponente, die es in erster Linie gilt zu optimieren • Elektrofahrzeuge stellen eine gewisse Herausforderung dar, weil sie jeder Zeit sich von dem Mikronetz trennen können → Elektrofahrzeuge wurde explizit nicht in dem Paper berücksichtigt
<p>Applications of reinforcement learning in energy systems (Link)</p>	<ul style="list-style-type: none"> • Paper ist eine Literaturübersicht über Reinforcement Learning, die Energiesysteme managen • State-of-the-Art-Verfahren wie Actor-Critic wurden selten in Experimenten verwendet, was nach den Autoren, zu starken Performanceeinbußen führte • Multi-Agent RL bieten zwar viel Potential, da sie Lösungen für komplexe Interaktionsprobleme zwischen mehreren Parteien finden → dennoch wurden bestimmte Verfahren aus diesem Gebiet nicht verwendet • Fazit: RL hat viel Potential Energieverteilungsprobleme effizient zu lösen 	

Titel	Ansatz	Unterschied zu unserem Use Case
Deep Reinforcement Learning for Smart Home Energy Management (Link)	<ul style="list-style-type: none"> • Energiekostenminimierung für ein Smart Home ohne ein Modell der thermischen Dynamik des Gebäudes unter Berücksichtigung eines komfortablen Temperaturbereichs • Energiebedingte Herausforderungen: Leistung der erneuerbaren Energien, nicht verschiebbarer Strombedarf, Außentemperatur und Strompreis • Energiesystem besitzt Speicher, Konsumenten und Erzeuger • Innerhalb eines Experiments wurde ein Markov-Entscheidungsprozess und ein Deep Deterministic Policy Gradients (DDPG) implementierung und miteinander verglichen • DDPG ist nach den Autoren vergleichsweise wirksam und robust 	<ul style="list-style-type: none"> • Konsumenten sind dauerhaft an das Stromnetz angeschlossen nicht wie Elektrofahrzeuge • Kostenminimierung steht wieder im Vordergrund
Werbeflächen zu vermieten – Hier könnte Ihre Werbung stehen.		
Smart Grid Optimization by Deep Reinforcement Learning over Discrete and Continuous Action Space (Link)	<ul style="list-style-type: none"> • Vergleich von Verfahren für diskrete und kontinuierliche Aktionsräume, die das Zielverfolgen, den Energiebedarf mittels verschiedener Energieversorger (extern & intern) zu decken 	<ul style="list-style-type: none"> • das Ziel von den Autoren vorgeschlagenen Modell ist es lediglich zu entscheiden, Energie zu kaufen oder zu verkaufen (im kontinuierlichen Aktionsraum: wie viel gekauft oder verkauft wird) → nicht kompatibel mit unserer Problemstellung

Titel	Ansatz	Unterschied zu unserem Use Case
<p>Deep Reinforcement Learning for Optimal Energy Management of Multi-energy Smart Grids (Link)</p>	<ul style="list-style-type: none"> • Deep Reinforcement Learning-Ansatz für die optimale Steuerung von Multi-Energie-Systemen in intelligenten Stromnetzen • Das hier verwendete Multi-Energie-Wohnungsmikronetzmodell besteht aus Strom-, Wärme- und Kältespeicher sowie thermische Produktionssysteme und erneuerbarer Energieerzeugung • Herausforderung: optimale Echtzeitsteuerung von Multi-Energie-Systemen mit mehreren gleichzeitigen kontinuierlichen Aktionsräumen • In einem Experiment wurde ein DDPG-Algorithmus getestet • Es wurde festgestellt, dass der DDPG-Agent kontinuierliche Zustands- und Aktionsräume gut handhaben kann 	<ul style="list-style-type: none"> • Keine Berücksichtigung von Elektrofahrzeugen